# Cahier de TP « Messagerie distribuée avec Kafka »

## <u>Pré-requis</u>:

- Bonne connexion Internet
- Système d'exploitation recommandé : Linux
- JDK8+
- IDE Recommandés : STS 4, IntelliJIDEA, VSCode
- Docker, Git

## **Atelier 1: Installation**

## 1. Installation Ensemble Zookeeper

Récupérer une distribution de Zookeeper.

https://downloads.apache.org/zookeeper/zookeeper-3.6.2/apache-zookeeper-3.6.2-bin.tar.gz

Créer un répertoire (ZK\_ENSEMBLE) pour stocker les fichiers de configuration des instance

Y créer 3 sous-répertoire 1,2 et 3

Dans chacun des répertoire créer un sous-répertoire *data* y créer un fichier nommé myid contenant l'identifiant de l'instance (1,2 et 3)

Copier dans chacun des répertoires le répertoire *conf* de la distribution

Dans chacun des répertoire éditer le fichier **zoo.cfg** , en particulier

- dataDir
- Les ports TCP utilisés

Se mettre au point un fichier sh permettant de démarrer les 3 instances

```
$ZK_HOME/bin/zkServer.sh --config $ZK_ENSEMBLECONF/1/conf start &&
$ZK_HOME/bin/zkServer.sh --config $ZK_ENSEMBLECONF/2/conf start
&&
```

\$ZK\_HOME/bin/zkServer.sh --config \$ZK\_ENSEMBLECONF/3/conf start

## Données partagées :

Connecter à l'instance 1 via :

./zookeeper-1/bin/zkCli.sh -server 127.0.0.1:2181

Créer une donnée et enregistrer un watcher :

```
create /dp hello
get -w /dp
```

Dans un autre terminal, se connecter à l'instance 2 et mettre à jour la donnée partagée ./zookeeper-2/bin/zkCli.sh -server 127.0.0.1:2182 set /dp world

Vous devez observer une notification dans le terminal 1

## Election et quorum

Afficher les rôles des serveurs avec la commande : echo stat | nc localhost 2181 | grep Mode && echo stat | nc localhost 2182 | grep Mode && echo stat | nc localhost 2183 | grep Mode

Stopper le serveur leader et observer la réélection

Stopper encore un serveur et interroger le serveur restant. L'ensemble n'ayant plus de quorum ne doit pas répondre

Redémarrer un serveur et observer la remise en service de le l'ensemble

## 2. Installation broker Kafka

Récupérer une distribution de Kafka

Démarrer un broker via :

./kafka-server-start.sh [-daemon] ../config/server.properties

Vérifier le bon démarrage via la console

Faites des vérification en créant un topic et envoyant des messages via les utilitaires.

Installer Kafka Magic

## 3. Mise en place cluster Kafka

Créer un répertoire *kafka-cluster* et 3 sous-répertoires : *broker-1*, *broker-2*, *broker-3* 

Copier le fichier server.properties dans le répertoire kafka-cluster

Mettre au point un script sh permettant de démarrer les 3 brokers en mode daemon qui surcharge 3 propriétés :

- broker.id
- logs.dir
- listeners

Visualiser les traces de démarrages :

tail -f \$KAFKA\_HOME/logs/server.log

Créer un topic *testing* avec 5 partitions et 2 répliques :

./kafka-topics.sh --create --bootstrap-server localhost:90982 --replication-factor 2 --partitions 5 -- topic testing

Lister les topics du cluster

Démarrer un producteur de message

./kafka-console-producer.sh --broker-list localhost:9092 --topic testing --property "parse.key=true" --property "key.separator=:"

Saisir quelques messages

Accéder à la description détaillée du topic

Visualiser les répertoires de logs sur les brokers :

./kafka-log-dirs.sh --bootstrap-server localhost:9092 --describe

Consommer les messages depuis le début

Dans une autre fenêtre, lister les groupes de consommateurs et accéder au détail du groupe de consommateur en lecture sur le topic *testing* 

## **Atelier 2: Producer API**

Importer le projet Maven fourni

Le projet est composé de :

- Une classe principale *KafkaProducerApplication* qui prend en arguments :
  - *nbThreads* : Un nombre de threads
  - nbMessages : Un nombre de messages
  - sleep : Un temps de pause
  - sendMode: Le mode d'envoi: 0 pour Fire\_And\_Forget, 1 pour Synchrone, 2 pour Asynchrone

L'application instancie *nbThreads KafkaProducerThread* et leur demande de s'exécuter ; quand toutes les threads sont terminées. Elle affiche le temps d'exécution

- Une classe *KafkaProducerThread* qui une fois instanciée envoie *nbMessages* tout les temps de pause selon un des 3 modes d'envoi.
  - Les messages sont constitués d'une au format String (*courier.id*) et d'une payload au format JSON (classe *Courier*)
- Le package *model* contient les classes modélisant les données
  - o **Position**: Une position en latitude, longitude
  - Courier : Un coursier associé à une position
  - **SendMode**: Une énumération des modes d'envoi

Compléter les méthodes d'envoi de *KafkaProducerThread*.

Pour cela vous devez:

- Initialiser un *KafkaProducer*<*String,Courier*> et y positionner des sérialiseurs JSON pour la classe *Courier*
- Construire un *ProducerRecord* pour chaque messages
- Implémenter les 3 méthodes d'envoi

Via les commandes utilitaires de Kafka, vérifier la création du topic et consommer les messages

Supprimer le topic et le recréer avec un nombre de *partitions=3* et un *replication-factor=2* 

Envoyer des messages

Construire un jar exécutable avec : *mvn package* 

## **Atelier 3: Consumer API**

## 2.1 Implémentation

Le projet est composé de :

- Une classe principale *KafkaConsumerApplication* qui prend en arguments :
  - *nbThreads* : Un nombre de threads
  - o sleep: Un temps de pause

L'application instancie *nbThreads KafkaConsumerThread* et leur demande de s'exécuter. Le programme s'arrête au bout d'un certains temps.

• Une classe *KafkaConsumerThread* qui une fois instanciée poll le topic position tout les temps de pause.

A la réception des messages, il affiche la clé, l'offset et le timesatmp de chaque message. Il met également à jour une Map qui contient le nombre de mise à jour pour chaque coursier

- Le package model contient les classes modélisant les données
  - *Position* : Une position en latitude, longitude
  - *Courier* : Un coursier associé à une position

Compléter la boucle de réception des messages

Pour cela, vous devez

- Initialiser un KafkaConsumer
- Fournir un Deserialiseur
- Implémenter la boucle de réception

Pour tester la réception, vous pouvez utiliser le programme précédent et le lancer afin qu'il exécute de nombreux message :

Par exemple:

producer\_home\$ java -jar target/producer-0.0.1-SNAPSHOT-jar-withdependencies.jar 10 100000 500 0

## 2.2 Tests

Une fois le programme mis au point, effectuer plusieurs tests

<u>Tester qu'aucun message n'est perdu :</u>

Démarrer le programme avec 1 thread arrêter puis redémarrer avec la même configuration

<u>Tester la réaffectation de partitions :</u>

Démarrer avec 2 threads puis 3 threads et visualiser la répartition des partitions

Démarrer également le programme avec 5 threads

# **Atelier 3-bis. Frameworks (Spring Boot/Quarkus)**

<u>Objectifs</u>: Écrire une application SpringBoot qui consomme les enregistrements du topic *position* précédent

Récupérer le projet Maven/SpringBoot fourni.

Le fichier pom.xml déclare en particulier les dépendances suivantes :

- spring-cloud-stream
- spring-cloud-stream-binder-kafka

Déclarer un Bean Spring ayant pour nom *position* de type *Consumer*<*Message*<*String*>>

Dans le fichier de configuration *src/main/resources/application.yml* :

- Utiliser le nom de la méthode annotée Bean pour binder le topic *position*
- Déclarer les bootstrap-servers Kafka

Tester en alimentant le topic

Récupérer le projet Maven/Quarkusfourni.

Le fichier pom.xml déclare en particulier les dépendances suivantes :

- quarkus-smallrye-reactive-messaging-kafka
- quarkus-resteasy-reactive-jackson

Déclarer un Bean PositionService déclarant un méthode de réception de message**ing**>>

Dans le fichier de configuration *src/main/resources/application.properties*:

Déclarer les bootstrap-servers Kafka

Tester en alimentant le topic

## **Atelier 4. Kafka Connect**

Objectifs : Déverser le topic *position* dans un index ElasticSearch

#### 4.1 Installations ElasticSearch + Connecteur

Démarrer *ElasticSearch* et *Kibana* en se plaçant dans le répertoire du fichier *docker-compose.yml* fourni, puis :

```
docker-compose up -d
Se connecter à kibana et dans la DevConsole exécuter:
PUT /position
{
    "mappings":{
        "properties": {
            "@timestamp": {
```

Récupérer le projet OpenSource ElasticSearchConnector de Confluent et se placer sur une release puis builder.

```
git clone <a href="https://github.com/confluentinc/kafka-connect-elasticsearch.git">https://github.com/confluentinc/kafka-connect-elasticsearch.git</a> cd kafka-connect-elasticsearch git checkout v11.0.3

mvn -DskipTests clean package
```

Copier ensuite toutes les librairies présentes dans target/kafka-connect-elasticsearch-11.0.3-package/share/java/kafka-connect-elasticsearch/ dans le répertoire libs de Kafka

## 4.1 Configuration Kafka Standalone

Démarrer *kafka-standalone* et alimenter le topic *position* 

Vous pouvez visualiser les effets du connecteur

- Via ElasticSearch: <a href="http://localhost:9200/position/">http://localhost:9200/position/</a> search
- Via Kibana: http://localhost:5601

Optionnel : Améliorer le fichier de configuration afin d'introduire le timestamp

## Atelier 5: KafkaStream

## Objectifs:

Écrire une mini-application Stream qui prend en entrée le topic *position* et écrit en sortie dans le topic *position-out* en ajoutant un timestamp aux valeurs d'entrée

Importer le projet Maven fourni, il contient les bonnes dépendances et un package *model* :

- Un champ timesatmp a été ajouté à la classe Courier
- Une implémentation de *Serde* permettant la sérialisation et la désérialisation de la classe *Courier* est fournie

Avec l'exemple du cours, écrire la classe principale qui effectue le traitement voulu

## **Atelier 6 : Fiabilité**

## 1. At Least Once, At Most Once

## Objectifs:

Explorer les différentes combinaisons de configuration des producteurs et consommateurs vis à vis de la fiabilité sous différents scénarios de test.

On utilisera un cluster de 3 nœuds avec un topic de 3 partitions et un mode de réplication de 2.

Le scénarios de test envisagé (Choisir un scénario parmi les 2):

- Redémarrage de broker(s)
- Ré-équilibrage des consommateurs

Les différentes combinaisons envisagées

- Producteur : *ack=0* ou *ack=all*
- Consommateur: auto-commit ou commits manuels

## Les métriques surveillés

- Producteur : Trace WARN ou +
- Consommateur : Trace Doublon ou messages loupés

#### Méthodes:

Supprimer le topic *position* 

Le recréer avec

```
./kafka-topics.sh --create --bootstrap-server localhost:9092 --replication-factor 2 --partitions 3 --topic position
```

Vérifier l'affectation des partitions et des répliques via :

```
./kafka-topics.sh --bootstrap-server localhost:9092 --describe --topic position
```

Récupérer les sources fournis et construire pour les 2 clients l'exécutable via

mvn clean package

Dans 2 terminal, démarrer 2 consommateurs : java -jar target/consumer-0.0.1-SNAPSHOT-jar-with-dependencies.jar 1 1000 >> log1.csv

java -jar target/consumer-0.0.1-SNAPSHOT-jar-with-dependencies.jar 1 1000 >> log2.csv

Dans un autre terminal, démarrer 1 producteur multi-threadé :

java -jar target/producer-0.0.1-SNAPSHOT-jar-with-dependencies.jar 20 5000 10
<0|1|2> <0|all>

Pendant la consommation des messages, en fonction du scénario : arrêter et redémarrer un broker ou un consommateur.

Un utilitaire *check-logs* est fourni permettant de détecter les doublons ou les offsets.

java -jar check-logs.jar <log.csv>

## 2. Exactly One

Modifier la configuration du producer afin d'autoriser l'idempotence.

Rejouer les scénarios de tests précédents

## **Atelier 7: Administration**

Exécuter les producteurs et les consommateurs pendant les opérations d'administration

## 7.1 Reassign partitions, Retention

Modifier le nombre de partitions de position à 8

Vérifier avec

./kafka-topics.sh --zookeeper localhost:2181 --describe --topic position

Ajouter un nouveau broker dans le cluster.

Réexécuter la commande

./kafka-topics.sh --zookeeper localhost:2181 --describe --topic position

Effectuer une réaffectation des partitions en 3 étapes

Visualiser les segments et apprécier la taille

Pour le topic *position* modifier le *segment.bytes* à 1Mo

Diminuer le *retention.bytes* afin de voir des segments disparaître

## 7.2 Rolling restart

Sous charge, effectuer un redémarrage d'un broker.

Vérifier l'état de l'ISR

## 7.3 Mise en place de SSL

Travailler dans un nouveau répertoire ssl

## # Créer son propre CA (Certificate Authority)

openssl req -new -newkey rsa:4096 -days 365 -x509 -subj "/CN=localhost" -keyout ca-key -out ca-cert -nodes

#### # Générer une paire clé publique/privé pour chaque serveur

keytool -keystore server.keystore.jks -alias localhost -validity 365 -genkey -keyalg RSA -storetype pkcs12

#### # Create Certificate signed request (CSR):

keytool -keystore server.keystore.jks -certreq -file cert-file -storepass secret -keypass secret -alias localhost

#### # Générer le CSR signé avec le CA

openssl x509 -req -CA ca-cert -CAkey ca-key -in cert-file -out cert-file-signed -days 365 -CAcreateserial -passin pass:secret

#### # Importer le certifcat CA dans le KeyStore serveur

keytool -keystore server.keystore.jks -alias CARoot -import -file ca-cert storepass secret -keypass secret -noprompt

#### # Importer Signed CSR dans le KeyStore

keytool -keystore server.keystore.jks -import -file cert-file-signed -storepass secret -keypass secret -noprompt -alias localhost

#### # Importer le certificat CA dans le TrustStore serveur

keytool -keystore server.truststore.jks -alias CARoot -import -file ca-cert storepass secret -keypass secret -noprompt

#### **#Importer le CA dans le client**

keytool -keystore client.truststore.jks -alias CARoot -import -file ca-cert storepass secret -keypass secret -noprompt

#### Configurer le listener SSL et les propriétés SSL suivante dans server.properties

ssl. key store. location = /home/dthibau/Formations/Kafka/github/solutions/ssl/server. key store. jkssl. key store. password = secret

ssl.key.password=secret

ssl.trust store. location = /home/dthibau/Formations/Kafka/github/solutions/ssl/server.trust store.jks = (a.t., b.t., b.t.,

ssl.truststore.password=secret

security.inter.broker.protocol=SSL

ssl.endpoint.identification.algorithm =

ssl.client.auth=none

Démarrer le cluster kafka et vérifier son bon démarrages

Dans les traces doivent apparaître :

Registered broker 1 at path /brokers/ids/1 with addresses: SSL://localhost:9192,

Vérifier également l'affichage du certificat avec :

openssl s\_client -debug -connect localhost:9093 -tls1\_2

## Mettre au point un fichier *client-ssl.properties* avec :

security.protocol=SSL

 $ssl.truststore.location = /home/dthibau/Formations/Kafka/github/solutions/ssl/client.truststore.jks\\ ssl.truststore.password = secret$ 

## Vérifier la connexion cliente avec par exemple

./kafka-console-producer.sh --broker-list localhost:9192 --topic ssl --producer.config client-ssl.properties

## 7.3.Bis (Optionnel): Authentification et ACL avec SCRAM

Voir https://medium.com/egen/securing-kafka-cluster-using-sasl-acl-and-ssl-dec15b439f9d

## 7.4 Mise en place monitoring Prometheus, Grafana

Dans un premier temps, démarré une *JConsole* et visualiser les Mbeans des brokers, consommateurs et producteurs

Dans un répertoire de travail *prometheus* 

## wget

https://repo1.maven.org/maven2/io/prometheus/jmx/jmx\_prometheus\_javaagent/0.6/jmx\_prometheus\_javaagent-0.6.jar

#### waet

https://raw.githubusercontent.com/prometheus/jmx\_exporter/master/e
xample\_configs/kafka-2\_0\_0.yml

Modifier le script de démarrage du cluster afin de positionner l'agent Prometheus :

KAFKA\_OPTS="\$KAFKA\_OPTS -javaagent:\$PWD/jmx\_prometheus\_javaagent0.2.0.jar=7071:\$PWD/kafka-0-8-2.yml" \

./bin/kafka-server-start.sh config/server.properties

Attention, Modifier le port pour chaque broker

Redémarrer le cluster et vérifier http://localhost:7071/metrics

Récupérer et démarrer un serveur prometheus

### wget

https://github.com/prometheus/prometheus/releases/download/v2.0.0/prometheus-2.0.0.linux-amd64.tar.gz

tar -xzf prometheus-\*.tar.gz

cd prometheus-\*

cat <<'EOF' > prometheus.yml

global:

```
scrape_interval: 10s
evaluation_interval: 10s
scrape_configs:
    job_name: 'kafka'
    static_configs:
```

targets:localhost:7071localhost:7072localhost:7073localhost:7074

#### **EOF**

./prometheus

Récupérer et démarrer un serveur Grafana

sudo apt-get install -y adduser libfontconfig1
wget https://dl.grafana.com/oss/release/grafana\_7.4.3\_amd64.deb
sudo dpkg -i grafana\_7.4.3\_amd64.deb

sudo /bin/systemctl start grafana-server Accéder à <a href="http://localhost:3000">http://localhost:3000</a> avec *admin/admin* 

Déclarer la datasource Prometheus

Importer le tableau de bord : <a href="https://grafana.com/grafana/dashboards/721">https://grafana.com/grafana/dashboards/721</a>

Les métriques des brokers devraient s'afficher